基于 MemoryNetwork 的推特流行度预测

盛俊杰，徐洪义，黄金根

10152510150，etc

1 问题描述

这次大作业我们小组选择的是推特流行度预测问题，通过用户之前发出的推特的内容，标签，转载数，以及用户自身的 follower_cnt 和 statuses_cnt 来预测一条新发的推特的最终转载数。

2 数据分析

我们所获得数据如下

- tweet_train.json / tweet_test_unlabel.json[list]
  - id[int]: tweet ID
  - user_id[int]: author ID
  - text[str]: raw text description
  - hashtags[list] : hashtags
  - retweet_count[int] **(train only)**: retweet count within three days
  - score[float] **(train only)**: popularity score, log2(retweet_count)
- tweet_user.json[dict]
  - key[int]: author ID
  - value[dict]:
    - followers_count[int]: number of followers
    - statuses_count[int]: number of statuses

cc

需要预测的任务是

- tweet_test_labeled.json
  - key[int]: tweet ID
  - value[float]: popularity score

cc

可以看到我们需要预测的是一条 tweet 的 $popularityscore$ ，而可以用来建立模型的属性有 $userid$，$text$，$hash\_tags$ 以及用户的特征 $followers\_count$，$statuses\_count$。大致先看下各个属性的特征好了：

1. $text$：文本数据，包含特殊字符 (需要去除)，长度一般在 60words 以内
2. $userid$：用户 id，训练集中有总共 134 个用户
3. $hash\_tags$：标签，有 413 个标签
4. $followers\_count$：关注者数目 50W ～ 3500W 之间
5. $statuses\_count$：发布状态数 1W ～ 165W 之间

再来看一下 $retweet\_count$ 的分布:

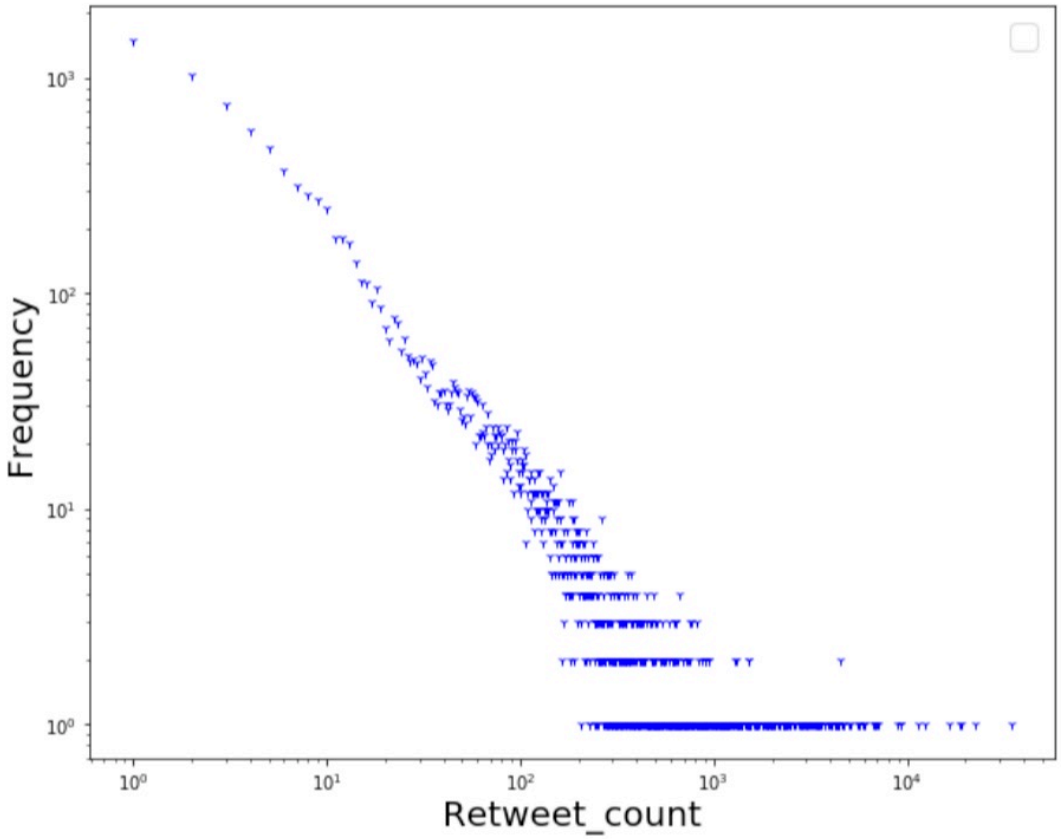

cc

可以看出高转发数的 tweet 出现频度是很低的，而大部分的转发数都是维持在较低的水平。

3 模型阐明

在这里我们采用的方法是使用 Memory NetWork 与张量分解结合形成的一个端到端的模型，原文中称之为 MOOD 模型。使用 Memory NetWork 获得文本的最佳表示，

3.1 模型总览

整个模型的输入由 *userid*，*text*，*hash_tags*，*followers_count*，*statuses_count* 组成，核心可分为 Memory Network 与 Tensor Factorization 两部分。模型图见下

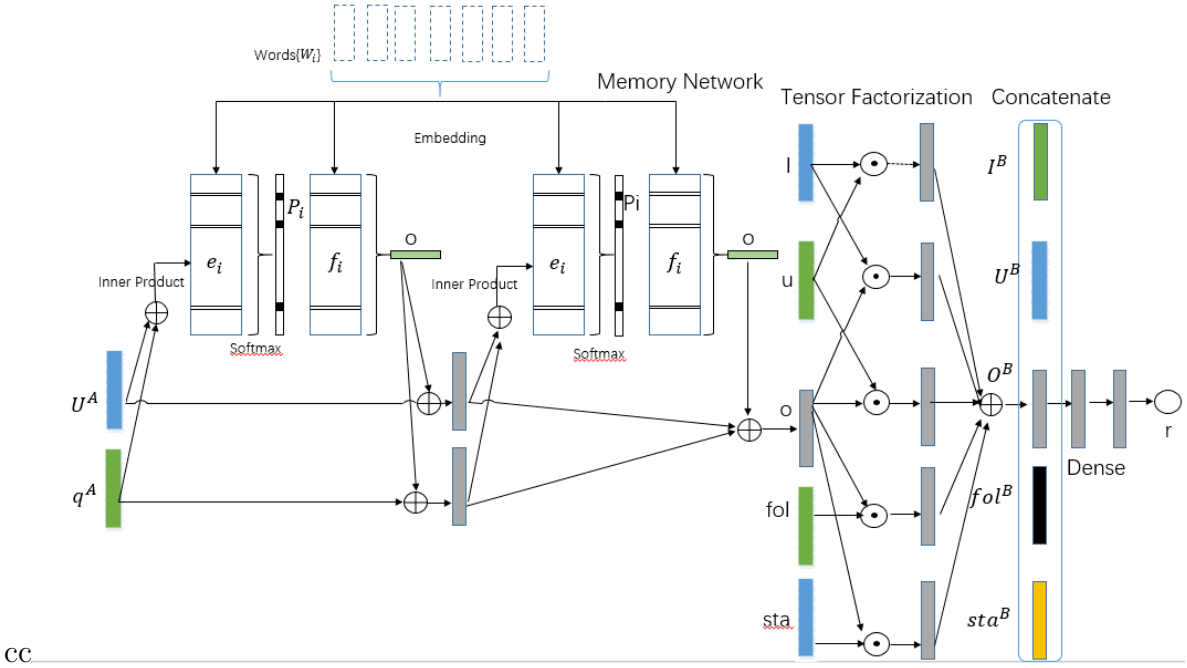

3.2 Memory Network

3.2.1 Memory Representation

在这个模块中，MOOD 分别定义了 memories for word,user 和 hash_tag。我们设字典大小为 $|V|$，文档长度为 L，嵌入维度为 k（这里又进一步假设 userid，hash_tag 的嵌入维度也为 k），我们将每一个单词都与 user 和 hash_tag 相关联，同时又为了考虑词序信息，我们将两个绝对位置编码矩阵 $E^p \in \mathbb{R}^{k\times L}$ 和 $F^p \in \mathbb{R}^{k\times L}$ 合并到基本词嵌入中。同时，MOOD 定义 user 和 hash_tag 的注意嵌入矩阵 $U^A \in \mathbb{R}^{k\times|Q|}$。那么有 $u_u^A = U_{:,u}^A$ 和 $q_q^A = Q_{:,u}^A$

3.2.2 Attention for Memory

在原始词汇空间中，文本介绍可以表示为一个热编码的序列（虽然在实现时我们是直接记录词典索引序列的，但为了论文描述方便）. 对于引言 d 中的第 j 个单词 w_j，热编码向量表

示为 $\hat{w_j} \in \{0,1\}^{|V|}$。假设 $v(j)$ 示词汇表中 w_j 的索引，我们可以得到嵌入 $e_{v(j)} = E\hat{w_j} + E^p_{:,j}$ 以类似的方式，也可以获得 $f_{v(j)}$

基于这些嵌入，MOOD 通过以下等式计算关于 v（j）的 user u 和 hash_tag q 的关注权重:

$$w^{u,q}_{v(j)} = (u^A_u + q^A_q)^T e_{v(j)}$$

这样我们就同时考虑进去了 user 和 hash_tag 两个特征。

3.2.3 Output Representation of Text

内存网络模块的核心目标是获得更好的活动介绍表示。首先计算 $p^{u,q}_{v(j)} = softmax(w^{u,q}_{v(j)})$ 代表 v（j）表示 d 的重要性的概率。单层记忆网络中学习到的 d 的表示记为 o:

$$o = \sum_j p^{u,q}_{v(j)} f_{v(j)}$$

3.2.4 Multi-layered Extension

类似于深度记忆网络采用的共同策略，MOOD 更新了每层之间的组织者和位置嵌入。Organizer u 和 location q 在第 k 层的嵌入分别表示为 $u^{A,K}_u$ 和 $q^{A,k}_q$。对于第一层, 有 $u^{A,1}_u = u^A_u$ 和 $q^{A,1}_q = q^A_q$. 按如下公式化迭代更新:

$$u^{A,K+1}_u = u^{A,K}_u + o^k$$

$$q^{A,K+1}_q = q^{A,K}_q + o^k$$

3.3 Tensor Factorization

在张量分解模块中,MOOD 定义了 $userid$,$text$,$hash\_tags$,$followers\_count$,$statuses\_count$ 的交互嵌入。它将五种嵌入模型组合在一起，以捕捉它们对活动流行度的共同影响。这个交互嵌入其实可以有怪多种定义方式，这里使用简单的乘积求和表达。公式如下:

$$\psi^{u,q}_d = u^I_u \bigodot q^I_q + u^I_u \bigodot o_d + q^I_q \bigodot o_d + f^I_f \bigodot o^I_o + s^I_s \bigodot o^I_o$$

通过经验可知（玄学），$userid$，$hash\_tags$，对于评分还是有很明显的偏置作用的。于是引入用户 u 和标签 q 的偏置嵌入 u^B_u 和 q^B_q 我们进一步连接偏置嵌入和集成嵌入，并将它们与完全连接层相关联以计算流行度 $\hat{r}$:

$$\hat{r} = \Theta^T \sigma(W^T_1[\psi^{u,q}_d; u^B_u; q^B_q] + b_1) + b$$

这里我们对其进行了改进，考虑到部分 user 在训练集出现次数较低，我们可能无法通过那少量的数据习得用户的特征，所以在 concate 时我们加入 $followers\_count$，$statuses\_count$ 两层，来更好的更话用户特征对流行度的预测。而在全连接层上我们选择了 2 层的隐层（全连接），再全连接到节点数为 1 的输出层。

4 代码构建

4.1 预处理

首先我们对 text 进行处理，首先进行预处理，去除链接与特殊字符，再进行词典编码，为了保留词序信息，这里我们按顺序记录每个词语的 index。实现如下

```
# judge if containAlpha
def containAlpha(wo内存表示: 在这个模块中，MOOD分别定义了单词，管理器和位置的内存rd):
    if len(word) ==0:
        return False
    else:
        if re.search('[a-z]', word):
            return True
        else:
            return False
# delete uri info
def deleteUri(text):
  textlist=text.split()
  resultlist=[]
  for word in textlist:
    if word.startswith('http'):
      continue
    if word.startswith('#'):
      resultlist.append(str(word[1:]))
    if containAlpha(word):
      resultlist.append(word)
  return ' '.join(resultlist)

def textPrecessing(text):
  text =text.lower()
  text=deleteUri(text)
  return text
```

```
27
28 from sklearn.feature_extraction.text import CountVectorizer
29 vectorizer =CountVectorizer(stop_words='english')
30 for item in data:
31   t=textPrecessing(item['text'])
32   #corpus is new text index matrix
33   corpus.append(t)
```

对于 hashtags 的处理同上

而对于 $followers\_count$，$statuses\_count$，我们将其分段来表示。

4.2 模型构建

模型使用以 tensorflow 为后端的 keras 构建，将其可视化后如下

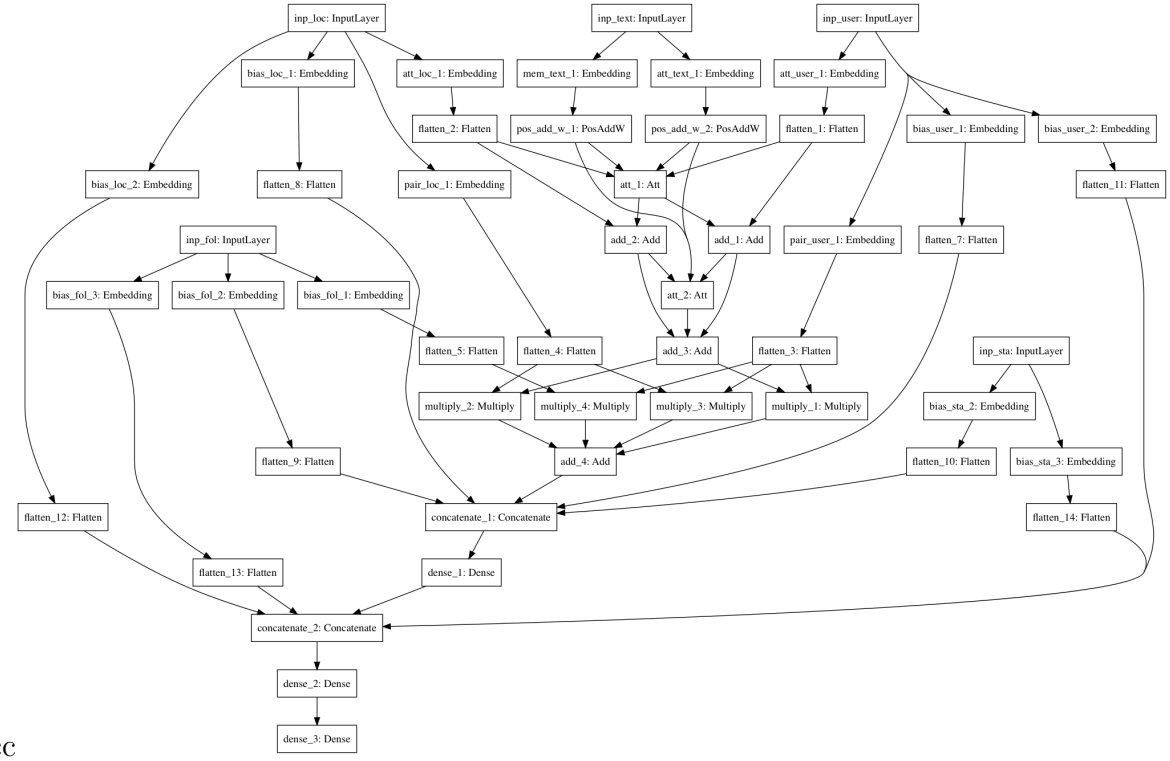

cc

5 实验过程

因为网络中的层数，隐层节点数，嵌入维度等都是一个个超参数，而这些超参对模型性能有一定的影响，所以在这里我们简要的记录我们的实验过程。

## 实验过程						
	vali		test			# 参数说明
	MSE	MAE	MSE	MAE		## 数据集划分
1层MOOD	0.6035	0.5432	0.3409	0.3727		all:7952
2层MOOD	0.6228	0.557	0.2787	0.3282		train:6090
3层MOOD	0.6462	0.5637	0.2508	0.3		vali:1862
4层MOOD	0.6555	0.5735	0.3821	0.4103		test:7952

cc

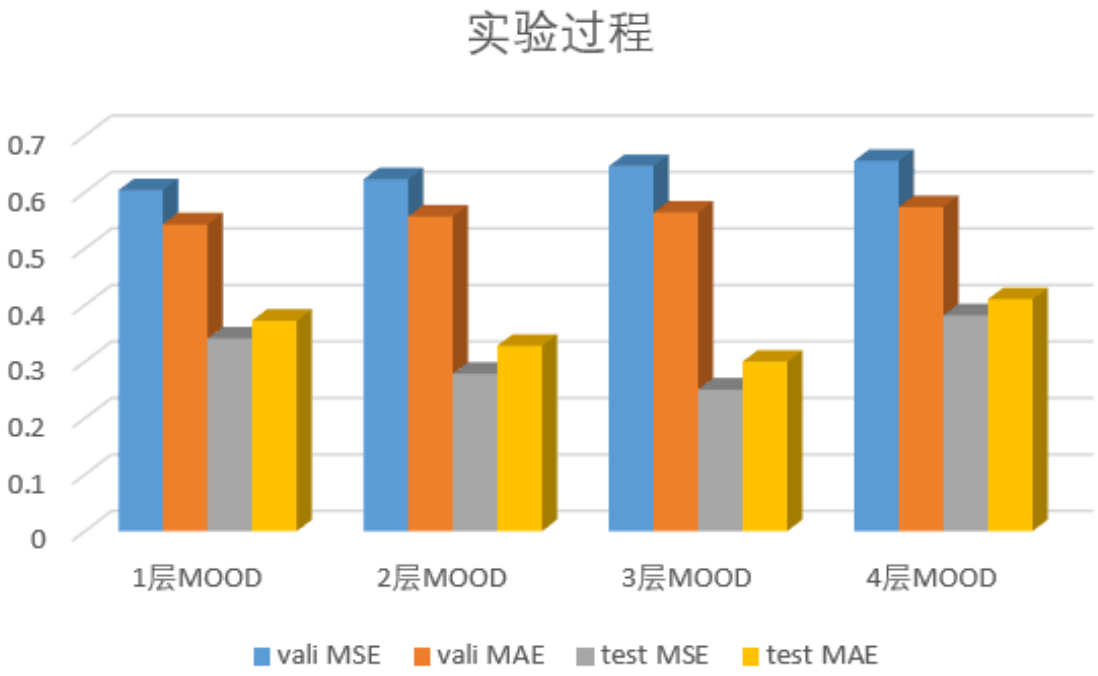

cc

我们同时也使用了传统机器学习算法设计了基准基准模型建立对比，结果如下：

	线性回归	KNN回归	SVM回归	随机森林回归	1层MOOD	2层MOOD	3层MOOD	4层MOOD
MSE	4.332	3.166	3.054	2.91	0.58	0.6228	0.6462	0.6555

	线性回归	KNN回归	SVM回归	随机森林回归	1层MOOD	2层MOOD	3层MOOD	4层MOOD
MSE	4.332	3.166	3.054	2.91	0.3409	0.2787	0.2508	0.3821

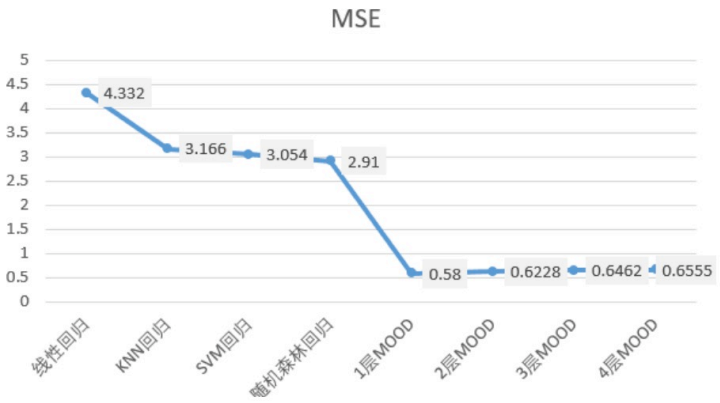

cc

6 结果

通过上述实验过程的比较，最终我们通过 1 层的 MOOD 对于 ublable 的数据进行预测，并将最终结果输出到 tweet_test_labeled.json 中。

7 More To Mention

这里说一下我们小组的分工:

1. 盛俊杰 MOOD 模型修改 + 报告
2. 徐洪义 MOOD 模型修改 +ppt
3. 黄金根预处理 + 基准模型 +ppt

Reference

[1] https://github.com/Autumn945/MOOD